基于状态感知双粒度关系对齐的扩散零样本学习

Abstract

1. Introduction

零样本学习（Zero-Shot Learning，ZSL）利用类别语义，将已见类中学习到的知识迁移至未见类。生成式 ZSL 根据语义条件合成未见类视觉特征，进而训练分类器，其关键在于学习可迁移的视觉—语义关联。作为代表性方法，ZeroDiff 结合扩散增强、实例对比表征与多视角判别，改善有限训练数据下的条件特征生成。在此基础上，如何进一步利用条件信息中蕴含的关系知识，是值得研究的问题。

类别语义与实例表征提供了互补的关系知识，但将二者作为生成条件，是否足以使生成特征保留跨类相对结构和类内实例差异？现有条件输入与判别监督能够间接学习结构，却未直接约束生成样本之间相对于这些参照的距离关系。即使生成特征具有类别判别性，其相对布局也可能不同。如图 1 所示，三个对象在参考表示中的远近次序，经过条件生成后仍可能发生反转。该示意说明，仅凭条件的使用或类别可分性，不能判断参考关系是否得到保持。因此，除单个特征与条件之间的对应关系外，还应考察生成特征之间的关系是否保留了有助于知识迁移的结构。

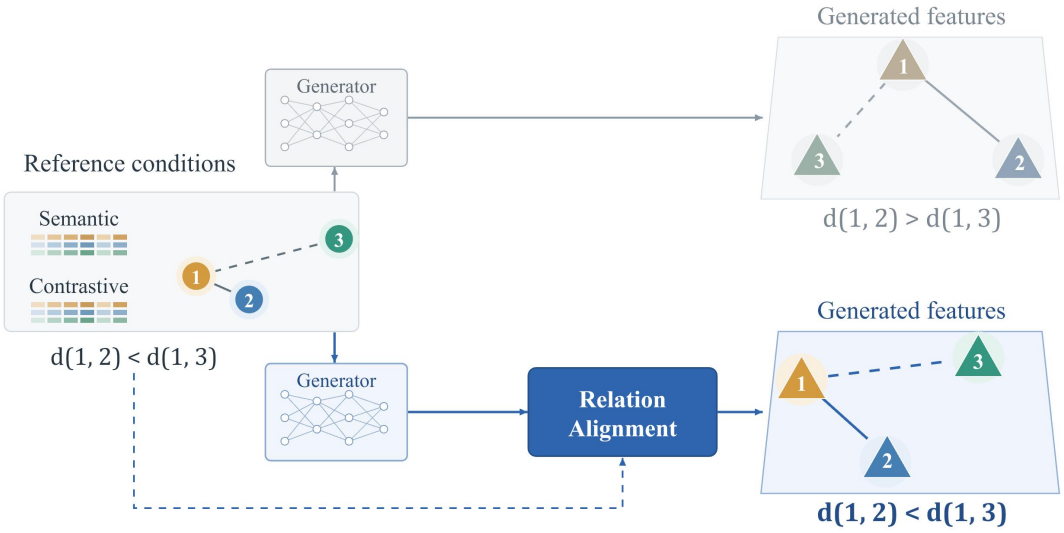


图 1 条件生成中的关系保持问题与显式关系监督的概念示意。上方展示条件输入未显式约束时可能出现的关系排序反转，下方展示引入参考关系监督的对齐目标。关系对齐作用于生成器训练，图中结果不代表实测数据。

显式利用这些关系知识，需要同时考虑监督范围与表示空间的差异。类别语义能够提供跨类关联线索，但同类实例共享语义原型，其语义距离为零，无法表达类内变化；实例对比表征则可补充同类样本间的相对差异。若不区分监督范围，直接对齐所有样本对的语义距离，可能对类内差异施加收缩约束。与此同时，类别语义、实例对比表征与视觉特征由不同学习目标塑造，其原始几何未必直接可比，语义距离也不应被视为真实视觉距离。因此，需要先建立关系比较的表示基础，再分别确定跨类关系与类内关系的监督对象。

在扩散生成中，关系监督还需考虑预测所依赖的噪声状态。尽管生成器在不同状态下均预测清洁特征，其输入保留的信号信息仍随噪声水平变化，预测的关系结构因而可能呈现不同的状态响应。引入关系监督时，需要控制关系比较的状态条件，并组织各状态的监督贡献。此外，跨类关系与类内关系依赖不同参照、面向不同对象，其状态敏感性不必预设为一致。为此，我们在相同扩散输入状态内构建关系，并允许两种粒度采用可分别调节的状态分配策略。

围绕上述目标，本文提出基于状态感知双粒度关系对齐的扩散零样本学习方法。首先，通过关系空间校准（Relational Space Calibration，RSC），利用真实已见类的视觉特征、实例对比表征与类别语义学习关系投影，为跨表示空间的关系比较建立基础。随后，同状态双粒度关系对齐（State-Matched Dual-Granularity Alignment，SDGA）以语义参照约束跨类关系，以实例对比参照约束同类不同实例关系，并将比较限定在相同扩散输入状态内。在此基础上，粒度感知状态重加权（Granularity-Aware State Reweighting，GSR）依据输入信号保留率组织两类关系的状态贡献，使监督分配兼顾关系粒度与噪声条件。三部分共同将互补关系知识显式融入 ZeroDiff 的基础生成训练。本文的主要贡献如下：

一、从关系保持的视角研究扩散式 ZSL，区分类别语义提供的跨类关系与实例表征提供的类内关系，将条件信息的利用进一步落实为生成特征对双粒度参考结构的显式学习。

二、提出状态感知双粒度关系对齐框架，在关系空间校准的基础上，按粒度限定监督范围、在同状态内实施关系对齐，并依据实际信号保留率分配状态贡献，形成统一的关系监督机制。

三、在 AWA2、CUB 和 SUN 上开展 ZSL 与 GZSL 实验，并通过有限训练数据比较和消融实验检验方法有效性。实验结果表明，所提方法在三个数据集的 T1 与 H 上均优于所采用的 ZeroDiff 基线。

2. Related Work

2.1.零样本学习

零样本学习（ZSL）借助类别属性、文本描述等辅助语义，将已见类别中学习到的知识迁移至未见类别。广义零样本学习（GZSL）进一步要求同时识别已见与未见类别。现有研究主要分为嵌入式与生成式两类，分别通过跨模态匹配和条件特征生成实现知识迁移。

嵌入式方法学习视觉特征与类别语义之间的映射或兼容性函数，依据样本与语义原型的

匹配程度完成识别。早期研究侧重全局表示的跨模态匹配，后续方法逐渐关注局部视觉区域与语义属性的对应关系。TransZero++通过双向属性引导的 Transformer 及语义协同学习增强属性定位与跨模态交互；ZSLViT 利用语义引导的令牌学习和视觉增强，逐步提取语义相关信息并压缩无关内容，提高表示的判别能力。

生成式方法以类别语义为条件合成未见类别的视觉特征，将零样本识别转化为监督分类问题。f-VAEGAN 结合变分自编码器与生成对抗网络建模类别条件分布；TF-VAEGAN 通过语义解码与反馈机制细化生成特征；CE-GZSL 融合特征生成与对比嵌入，利用类别级和实例级监督学习判别性表示。CESAM、FCMFD 等模型进一步从结构对齐和特征解耦入手，将关系约束与判别性表示学习融入特征生成，缓解视觉—语义结构差异及类别混淆。

后续研究进一步改进生成条件与优化目标：DSP 和 VADS 通过动态语义更新增强视觉—语义关联；GenZSL 结合类别名称语义与相似已见类别的视觉信息辅助生成；RLVC 利用结果奖励与视觉线索引入下游识别反馈。这些研究推动了生成特征的语义一致性与判别性学习。

2.2.零样本学习中的扩散模型

扩散模型通过前向加噪和逆向去噪学习数据分布，为条件生成提供了新的途径。DDPM 建立了基于逐步去噪的生成框架；DDGAN 利用条件生成对抗网络建模去噪转移，使模型能够采用较大的去噪步长，在减少采样步数的同时保持生成质量与多样性。将扩散机制引入零样本学习，可以在不同噪声水平下学习语义条件与视觉特征之间的关联，为未见类别的特征合成提供支持。

ZeroDiff 针对有限已见样本下的虚假视觉—语义关联，将扩散增强、监督对比表征和多判别器互学习结合：通过加噪扩充训练数据，以实例对比表征补充类别语义，并从语义、表征和扩散过程三个视角评价生成特征。该方法分别训练表征生成器与视觉特征生成器，依次合成未见类别的实例表征和视觉特征。在此基础上，Li 等人提出 ZeroDiff++，关注不同类别在固定扩散日程下的语义扩散不平衡。该方法引入采用弱噪声日程的 W 分支与采用平缓日程的 M 分支，分别侧重细粒度信息保留和去噪动态稳定，并通过语义引导的多候选融合细化生成特征。

本文进一步关注生成特征对跨类语义关系与类内实例关系的保持，在同一扩散输入状态下分别对齐两类结构，并依据关系粒度与信号保留率分配状态监督贡献。

3. Methodology

3.1. 问题设定

零样本学习包含互不相交的已见类别集 $\mathcal{Y}^s$ 与未见类别集 $\mathcal{Y}^u$，即 $\mathcal{Y}^s \cap \mathcal{Y}^u = \varnothing$。训练

集为 $\mathcal{D}_{\mathrm{tr}}=\{(x_i,y_i,\boldsymbol{a}_i)\}_{i=1}^{N_s}$，其中 N_s 为样本数，$x_i\in\mathcal{X}^s$ 为已见类图像，$y_i\in\mathcal{Y}^s$ 为标签，$\boldsymbol{a}_i=\boldsymbol{a}_{y_i}$ 为类别语义。未见类语义可用于生成，其真实图像不参与训练。传统 ZSL 的目标是学习分类器 $f_{\mathrm{ZSL}}:\mathcal{X}^u\to\mathcal{Y}^u$；GZSL 还需识别未参与训练的已见类样本，目标为 $f_{\mathrm{GZSL}}:\mathcal{X}^s\cup\mathcal{X}^u\to\mathcal{Y}^s\cup\mathcal{Y}^u$。

3.2.状态感知双粒度关系对齐

类别语义与实例对比表征分别提供跨类结构和类内差异信息，但将二者输入生成器，并不直接约束生成特征对这些关系的保持。同时，扩散输入的噪声水平改变了生成预测的信息条件，因此关系监督需要兼顾知识粒度与扩散状态。

我们在 ZeroDiff 的基础生成训练中引入状态感知双粒度关系对齐，由关系空间校准（RSC）、同状态关系对齐（SDGA）和粒度感知状态重加权（GSR）组成，分别确定关系比较的表示基础、监督对象和状态贡献。

3.2.1. 关系空间校准

视觉与对比表征由不同学习目标塑造，其原始关系几何未必适合直接监督生成。距离归一化可以调整整体尺度，却不能自动消除结构偏差。为此，关系空间校准（Relational Space Calibration，RSC）利用真实已见类数据学习关系投影，为后续生成关系约束建立比较基础。

记样本 i 的清洁视觉特征、实例对比表征与类别语义为 $\boldsymbol{v}_{0,i}$、$\boldsymbol{r}_{0,i}$ 和 $\boldsymbol{a}_i=\boldsymbol{a}_{y_i}$。投影器得到 $\boldsymbol{u}_i=E_v(\boldsymbol{v}_{0,i})$ 与 $\boldsymbol{h}_i=E_r(\boldsymbol{r}_{0,i})$，并对输出进行 ℓ_2 归一化。我们以归一化距离描述样本间的相对分离，以三元组方向描述围绕共同中心的相对布局。对于批次表示 $H=\{\boldsymbol{h}_i\}_{i=1}^{N}$，令 $d_{ij}(H)=\|\boldsymbol{h}_i-\boldsymbol{h}_j\|_2$，定义

$$\widehat{d}_{ij}(H)=\frac{d_{ij}(H)}{\max(\mu(H),\epsilon)},$$

$$\mu(H)=\frac{1}{|\mathcal{E}_H^+|}\sum_{(i,j)\in\mathcal{E}_H^+}d_{ij}(H),$$

$$\psi_{ijk}(H)=\left\langle\frac{\boldsymbol{h}_i-\boldsymbol{h}_j}{\max(d_{ij}(H),\epsilon)},\frac{\boldsymbol{h}_k-\boldsymbol{h}_j}{\max(d_{kj}(H),\epsilon)}\right\rangle.$$

其中，$\mathcal{E}_H^+=\{(i,j):i\neq j,\ d_{ij}(H)>0\}$，$\epsilon>0$ 为数值稳定常数；无非零距离时归一化尺度取 1。对于两组具有样本对应关系的表示 P 和 Q，分别在样本对与三元组上平均匹配关系：

$$\mathcal{L}_d(P,Q)=\frac{1}{N^2}\sum_{i,j=1}^{N}\ell_{\mathrm{SL1}}\quad\big(\widehat{d}_{ij}(P)-\widehat{d}_{ij}(Q)\big),$$

$$\mathcal{L}_a(P,Q)=\frac{1}{N^3}\sum_{i,j,k=1}^{N}\ell_{\mathrm{SL1}}\quad\big(\psi_{ijk}(P)-\psi_{ijk}(Q)\big).$$

其中，ℓ_{SL1} 为 Smooth L1 函数。记统一关系目标为 $\mathcal{R}(P,Q)=\lambda_d\mathcal{L}_d(P,Q)+\lambda_a\mathcal{L}_a(P,Q)$，

λ_d 与 λ_a 控制距离与方向的贡献，第二个变量作为停止梯度的参照。

令真实视觉投影、对比投影与类别语义的批次表示为 U、H 和 A，校准目标为

$$\mathcal{L}_{\mathrm{RSC}} = \eta_1 \mathcal{R}(U, A) + \eta_2 \mathcal{R}(U, \mathrm{sg}(H)) + \eta_3 \mathcal{R}(H, A).$$

其中，$\mathrm{sg}(\cdot)$ 表示停止梯度，$\eta_1, \eta_2, \eta_3 \geq 0$ 为校准系数。视觉投影同时匹配语义与对比关系，对比投影接受语义锚定；第二项不更新 E_r。同类语义重合会使第三项对类内相对距离产生收缩压力，η_3 调节这一锚定强度。

3.2.2. 同状态双粒度关系对齐

类别语义对同类实例给出零距离，无法表达类内变化；将其用于实例关系监督会产生类内收缩压力。因此，同状态双粒度关系对齐（State-Matched Dual-Granularity Alignment，SDGA）以类别语义监督跨类关系，以实例对比表征监督类内不同实例关系。对比表征的监督范围在此被限定为类内，以补充类别语义不能提供的细粒度结构。

预测目标同为清洁特征，并不意味着不同时间步的预测具有相同的误差特征。输入噪声水平的变化可能带来不同的结构偏差，混合这些预测会将噪声条件差异引入样本关系的构建。因此，我们在同一扩散输入状态内比较生成预测，以控制关系比较的噪声条件。对于分配至生成步 t_i 的样本 i，定义

$$\tilde{\boldsymbol{v}}_{0,i}^{(t_i)} = G\big(\boldsymbol{z}_i, \boldsymbol{a}_i, \boldsymbol{r}_{0,i}, \boldsymbol{v}_{t_i+1,i}, t_i\big),$$
$$\tilde{\boldsymbol{u}}_i^{(t_i)} = E_v\left(\tilde{\boldsymbol{v}}_{0,i}^{(t_i)}\right).$$

上标 (t_i) 表示预测所依赖的输入状态，类别语义 $\boldsymbol{a}_i$ 与对比投影 $\boldsymbol{h}_i$ 保持为清洁参照。同状态匹配使输入噪声水平可比，各实例仍使用独立噪声，预测误差也不被假定为一致。状态 t 下的两组关系对为

$$\mathcal{P}_C(t) = \{(i,j) : t_i = t_j = t,\ y_i \neq y_j\},$$
$$\mathcal{P}_I(t) = \{(i,j) : t_i = t_j = t,\ y_i = y_j,\ i \neq j\}.$$

跨类分离与类内差异具有不同尺度，共用归一化尺度会使两类关系相互影响。我们因此按粒度与状态分别归一化，并为生成表示和参考表示各自计算尺度。对于 $g \in \{C, I\}$，定义

$$\widehat{d}_{ij}^{\,g,t}(H) = \frac{d_{ij}(H)}{\max(\mu_{g,t}(H), \epsilon)}, \qquad \mu_{g,t}(H) = \frac{1}{|\mathcal{P}_g^+(t;H)|} \sum_{(i,j)\in\mathcal{P}_g^+(t;H)} d_{ij}\,(H),$$

其中，$\mathcal{P}_g^+(t;H)$ 为 $\mathcal{P}_g(t)$ 中距离为正的样本对集合，空集合沿用 RSC 的尺度约定。令 $\widetilde{U}$ 为当前批次的生成视觉投影，状态损失为

$$\mathcal{L}_C(t) = \frac{1}{|\mathcal{P}_C(t)|} \sum_{(i,j)\in\mathcal{P}_C(t)} \ell_{\mathrm{SL1}} \quad \left(\widehat{d}_{ij}^{\,C,t}(\widetilde{U}) - \widehat{d}_{ij}^{\,C,t}(A)\right),$$

$$\mathcal{L}_I(t) = \frac{1}{|\mathcal{P}_I(t)|} \sum_{(i,j)\in\mathcal{P}_I(t)} \ell_{\mathrm{SL1}} \quad \left(\widehat{d}_{ij}^{\,I,t}(\widetilde{U}) - \widehat{d}_{ij}^{\,I,t}(H)\right).$$

两类损失分别约束跨类语义结构与类内实例结构。参考关系停止梯度，生成距离及其归一化尺度参与反向传播。RSC 在真实批次上利用距离与方向共同校准比较空间；SDGA 的监督范围由两类样本对确定，因此生成阶段采用相对距离实施粒度分工，不额外构造各状态的三元组约束。

为提供有效关系对，训练采用 $P \times K$ 类别均衡采样，并按类别分配时间步，使同类实例共享状态、各状态包含多个类别，每类包含不同实例。记 $\mathcal{T}_g = \{t: |\mathcal{P}_g(t)| > 0\}$ 为有效状态集合，各状态先平均样本对损失，再进行状态聚合，以区分关系对数量与状态贡献。

3.2.3. 粒度感知状态重加权

SDGA 在各扩散状态内分别约束跨类语义关系与类内实例关系，但不同状态下生成器能够利用的视觉信号有所不同。为使关系监督随实际噪声水平调整，我们引入粒度感知状态重加权（Granularity-Aware State Reweighting，GSR），以生成器输入的信号保留率参数化两类关系的状态权重。该机制分别设置类别级与实例级关系的状态敏感性，使两类监督能够采用不同的状态分配曲线；同时引入非零权重下限，以保留低信号状态下的关系监督。

生成步 t 的输入为 $\boldsymbol{v}_{t+1}$，以 $s_t = \bar{\alpha}_{t+1}$ 表征其信号保留率，其中 $\bar{\alpha}$ 为扩散日程的累计信号系数。相较线性时间步索引，该量直接对应实际日程中的信号变化。对于 $g \in \{C, I\}$，采用可调幂函数构造权重：

$$a_g(t) = f + (1-f)s_t^{p_g}, \qquad w_g(t) = \frac{a_g(t)}{\frac{1}{T}\sum_{\tau=0}^{T-1} a_g(\tau)}.$$

其中，$0 < f \le 1$ 保留高噪声状态的监督，$p_g \ge 0$ 调节衰减曲线。设置 $p_I > p_C$ 且 $f < 1$，会使实例级原始权重在中低信号状态下衰减得更快。完整日程归一化使每种粒度的权重均值为 1，从而将状态分配 $w_g(t)$ 与粒度强度 λ_C, λ_I 区分开；原始权重的跨粒度大小关系不必在归一化后逐点保持。共享指数对应共享调度，零指数恢复等权监督。

重加权后的粒度损失及联合生成目标为

$$\mathcal{L}_g^{\mathrm{GSR}} = \frac{1}{\max(1, |\mathcal{T}_g|)} \sum_{t\in\mathcal{T}_g} w_g(t)\mathcal{L}_g(t),$$

$$\mathcal{L}_{\mathrm{GSR}} = \lambda_d\left(\lambda_C\mathcal{L}_C^{\mathrm{GSR}} + \lambda_I\mathcal{L}_I^{\mathrm{GSR}}\right),$$

$$\mathcal{L}_G = \mathcal{L}_{\mathrm{base}} + \gamma_{\mathrm{rel}}\mathcal{L}_{\mathrm{GSR}}.$$

其中，$\lambda_C, \lambda_I \ge 0$ 分别控制两种粒度的监督强度，$\gamma_{\mathrm{rel}} \ge 0$ 控制关系监督的整体贡献，$\mathcal{L}_{\mathrm{base}}$ 沿用 ZeroDiff 的基础生成目标。权重始终按完整日程归一化，损失按有效状态数聚合，

不依据当前批次的权重和重新归一化。

3.3.整体概述

训练时，先利用真实已见类批次更新关系投影器，再固定其参数，以关系目标与基础生成目标联合更新视觉生成器；关系梯度仍可经 E_v 传回生成器，基础判别器按原有目标更新。训练完成后，冻结扩散表征生成器 G_r^* 与视觉特征生成器 G^*。推理时，G_r^* 根据未见类别语义合成对比表征，G^* 进一步以类别语义和合成表征为条件生成视觉特征，随后利用合成数据训练轻量分类器完成零样本识别。

4. Experiments

我们在 AWA2、CUB 和 SUN 三个基准数据集上评估所提方法。首先比较完整训练数据下的 ZSL 与 GZSL 性能，随后考察训练样本受限时的表现，并通过消融实验分析两种粒度的关系约束与状态重加权的作用。最后，利用真实与生成特征的可视化，观察不同训练样本比例下的分布特征。

4.1.Experimental Settings

数据集。AWA2 包含 37,322 张动物图像，共 50 个类别，其中已见类和未见类分别为 40 类和 10 类；CUB 包含 11,788 张鸟类图像，共 200 个类别，划分为 150 个已见类和 50 个未见类；SUN 包含 14,340 张场景图像，共 717 个类别，划分为 645 个已见类和 72 个未见类。三个数据集分别覆盖动物识别、细粒度鸟类识别和场景识别。实验沿用 ZeroDiff 的类别划分，未见类别的真实图像不参与生成模型训练。

评价指标。ZSL 仅在未见类别中进行分类，报告未见类平均每类 Top-1 准确率 T1。GZSL 的候选标签同时包含已见类与未见类，分别报告两类测试样本的平均每类准确率 S 和 U，并采用调和平均值 $H = 2SU/(S + U)$ 衡量二者的综合表现。所有准确率以百分数表示，文中性能差值均以百分点计。

实现细节。本文基于 ZeroDiff 的两阶段生成框架实现。视觉特征和实例对比表征分别采用其交叉熵与 PaCo 表征分支，视觉特征维度为 2,048。AWA2 和 SUN 分别使用 85 维和 102 维类别属性，CUB 使用由文本描述提取的 1,024 维语义表示。模型采用 Adam 优化器，扩散步数设为 4，关系投影维度为 512。关系学习采用类别均衡采样，每批选取 16 个类别、每类 4 个实例，并按类别分配扩散状态。训练时先在真实已见类数据上更新关系投影器，再固定投影器参数，以关系损失与基础生成目标共同优化视觉生成器。测试时根据未见类语义生成特征，并训练分类器完成识别。

4.2.Comparison with State-of-the-Art Methods

表 1 汇总了本文方法与代表性方法的比较结果，包括 MSDN、PSVMA、ZSLViT、PSVMA+ 和 AENet 等嵌入式方法，以及 CE-GZSL、FREE、RE-GZSL、VADS、GenZSL、RLVC 和 ZeroDiff 等生成式方法，同时列出近期方法 SAGE。我们重点考察相对于基础生成框架 ZeroDiff 的变化，并结合表中其他方法评价所提方法的性能。不同方法采用的视觉骨干与语义表示并不完全相同，因此，跨方法结果主要反映各自完整配置下的识别表现。

表 1 在 AWA2、CUB 和 SUN 上的 ZSL 与 GZSL 性能比较。T1、U、S 和 H 的单位均为 %；“–”表示未提供结果。

Method	Source	ZSL			GZSL								
		AWA2	CUB	SUN	AWA2			CUB			SUN		
		T1	T1	T1	U	S	H	U	S	H	U	S	H
CE-GZSL	21CVPR	70.4	77.5	63.3	63.1	78.6	70.0	63.9	66.8	65.3	48.8	38.6	43.1
FREE	21ICCV	-	-	-	60.4	75.4	67.1	55.7	59.9	57.7	47.4	37.2	41.7
MSDN	22CVPR	70.1	76.1	65.8	62.0	74.5	67.7	68.7	67.5	68.1	52.2	34.2	41.3
PSVMA	23CVPR	-	-	-	73.6	77.3	75.4	70.1	77.8	73.8	61.7	45.3	52.3
RE-GZSL	24TCSVT	73.1	78.9	-	67.7	81.1	73.8	72.3	62.4	67.0	-	-	-
ZSLViT	24CVPR	70.7	78.9	68.3	66.1	84.6	74.2	69.4	78.2	73.6	45.9	48.3	47.3
VADS	24CVPR	82.5	86.8	76.3	75.4	83.6	79.3	74.1	74.6	74.3	64.6	49.0	55.7
PSVMA+	25TPAMI	79.2	78.8	74.5	74.2	86.4	79.8	71.8	77.8	74.6	61.5	49.4	54.8
GenZSL	25ICML	92.2	-	73.5	86.1	88.7	87.4	53.5	61.9	57.4	50.6	43.8	47.0
AENet	25AAAI	75.2	80.3	70.4	70.3	80.1	74.9	73.1	76.4	74.7	58.6	45.2	51.0
SAGE	26AAAI	83.7	82.1	77.2	78.1	87.2	82.4	75.1	77.5	76.3	63.7	52.2	57.4
RLVC	26CVPR	84.0	90.1	77.7	78.4	82.4	80.4	80.9	81.4	81.2	59.6	55.6	57.6
ZeroDiff	25ICLR	81.5	87.5	76.4	73.3	88.1	80.1	80.0	83.2	81.6	58.5	58.8	58.7
Ours	**-**	**86.4**	**88.2**	**77.8**	**74.8**	**89.3**	**81.4**	**82.8**	**83.1**	**83.0**	**61.6**	**57.9**	**59.7**

ZSL 结果。本文方法在 AWA2、CUB 和 SUN 上的 T1 分别达到 86.4%、88.2% 和 77.8%，相对于表中的 ZeroDiff 分别提高 4.9、0.7 和 1.4 个百分点。其中，SUN 上的结果略高于 RLVC 的 77.7%，为表中最高值；AWA2 上低于 GenZSL 的 92.2%，CUB 上低于 RLVC 的 90.1%。因此，所提方法在三个数据集上均改善了基础框架的未见类识别性能，但其相对其他方法的优势随数据集而变化。

GZSL 结果。本文方法在三个数据集上的 H 分别为 81.4%、83.0% 和 59.7%，相对于 ZeroDiff 分别提高 1.3、1.4 和 1.0 个百分点。在 CUB 和 SUN 上，本文方法取得表中最

高的 H；在 AWA2 上，其 H 高于 ZeroDiff 和 RLVC，但仍低于 GenZSL 与 SAGE。这些结果表明，在所评估的数据集上，引入关系监督能够改善基础框架的综合识别表现，其中 CUB 和 SUN 上的优势更为突出。

进一步观察 U 与 S，AWA2 上二者相对于 ZeroDiff 分别提高 1.5 和 1.2 个百分点。CUB 上 U 从 80.0% 提高至 82.8%，S 则从 83.2% 小幅下降至 83.1%；SUN 上 U 从 58.5% 提高至 61.6%，S 从 58.8% 下降至 57.9%。后两个数据集上的 H 提升主要伴随未见类准确率的提高，而非已见类与未见类准确率的同步增长。

4.3.Limited Training Data

为考察训练数据受限时的表现，我们在 AWA2 和 SUN 上分别采用 30% 与 10% 的已见类训练样本，将本文方法与 ZeroDiff 进行比较。表 2 报告两种训练比例下的 ZSL T1 和 GZSL H，以考察完整数据条件下观察到的收益能否延续至较少训练样本的情形。

表 2 已见类训练样本受限时的性能比较。30% 和 10% 表示保留的已见类训练样本比例；T1 与 H 的单位均为 %。

Method	AWA2				SUN			
	30%D^{tr}		10%D^{tr}		30%D^{tr}		10%D^{tr}	
	T1	H	T1	H	T1	H	T1	H
ZeroDiff	83.0	78.2	82.9	76.4	73.5	51.2	58.1	30.5
Ours	**84.2**	**79.1**	**84.1**	**77.4**	**75.3**	**52.3**	**60.1**	**31.8**

在 AWA2 上，采用 30% 训练样本时，本文方法的 T1 和 H 分别为 84.2% 和 79.1%，较 ZeroDiff 提高 1.2 和 0.9 个百分点；采用 10% 训练样本时，两项指标为 84.1% 和 77.4%，分别提高 1.2 和 1.0 个百分点。在这两个训练比例下，本文方法均保持了相对于基础框架的性能增益。

在 SUN 上，采用 30% 训练样本时，T1 和 H 分别较 ZeroDiff 提高 1.8 和 1.1 个百分点；采用 10% 训练样本时，增益分别为 2.0 和 1.3 个百分点。不过，随着训练样本比例从 30% 降至 10%，本文方法的 T1 仍从 75.3% 降至 60.1%，H 从 52.3% 降至 31.8%。因此，这组结果支持所提方法在已测试的低样本条件下优于 ZeroDiff，同时也表明训练样本减少仍会明显限制 SUN 上的识别性能。

4.4.Ablation Study

为分析各设计的作用，我们在三个数据集上比较完整模型与五种变体，结果见表 3。w/o Class Alignment 与 w/o Instance Alignment 分别移除生成阶段的跨类语义关系约束和类内实例关系约束；w/o Class & Instance Alignment 同时移除这两项约束。对于状态权重，w/o GSR 对各状态采用等权监督，Shared State Weights 则对两种粒度使用共享的状态权重。

表 3 双粒度关系约束与状态重加权的消融结果。各数据集分别报告 ZSL T1 和 GZSL H，单位均为 %。

Methods	AWA2		CUB		SUN	
	T1	H	T1	H	T1	H
w/o Class Alignment	84.3	78.1	87.9	80.7	76.1	57.6
w/o Instance Alignment	83.4	76.6	86.5	81.5	74.9	56.3
w/o GSR	83.5	79.8	86.1	80.8	75.9	57.6
Shared State Weights	83.3	79.9	86.6	81.8	76.9	58.4
w/o Class & Instance Alignment	80.8	75.2	82.5	77.7	72.9	55.2
Full Model (Ours)	**86.4**	**81.4**	**88.2**	**83.0**	**77.8**	**59.7**

双粒度关系约束。移除跨类约束后，AWA2、CUB 和 SUN 上的 T1 分别下降 2.1、0.3 和 1.7 个百分点，H 分别下降 3.3、2.3 和 2.1 个百分点；移除类内约束后，T1 分别下降 3.0、1.7 和 2.9 个百分点，H 分别下降 4.8、1.5 和 3.4 个百分点。两种约束在三个数据集的两项指标上均带来收益，但其贡献大小并不一致。例如，AWA2 和 SUN 上移除类内约束造成的 H 降幅更大，而 CUB 上移除跨类约束的 H 降幅更大。这一结果与分别利用类别语义和实例表征提供不同粒度监督的设计动机一致。

同时移除两项生成关系约束后，三个数据集上的 T1 分别降至 80.8%、82.5% 和 72.9%，H 分别降至 75.2%、77.7% 和 55.2%。相较该变体，完整模型的 T1 分别提高 5.6、5.7 和 4.9 个百分点，H 分别提高 6.2、5.3 和 4.5 个百分点。结合单项移除结果，联合使用两种粒度的约束优于仅保留其中一种，支持二者在当前框架中的互补作用。该变体仍保留关系空间校准与调整后的训练组织，其配置与表 1 中的 ZeroDiff 不同。

状态重加权。相对于 w/o GSR，完整模型在三个数据集上的 T1 分别提高 2.9、2.1 和 1.9 个百分点，H 分别提高 1.6、2.2 和 2.1 个百分点。相对于 Shared State Weights，完整模型的 T1 分别提高 3.1、1.6 和 0.9 个百分点，H 分别提高 1.5、1.2 和 1.3 个百分点。共享权重相较等权监督并非在所有指标上都有改善，例如其在 AWA2 上的 T1 为 83.3%，略低于等权变体的 83.5%。相比之下，完整模型在这组对照中取得一致增益，支持按粒度分配状态贡献的设计。

4.5.Qualitative Analysis

为直观观察生成特征的分布，我们在 AWA2 未见类别上对真实特征与生成特征进行 t-SNE 可视化。如图 2 所示，上、下两排分别对应 ZeroDiff 和本文方法，三列分别采用 100%、30% 与 10% 的已见类训练样本。每个类别展示 100 个生成样本及全部真实样本，以颜色区分类别，并分别用空心圆和星形标记真实特征与生成特征。

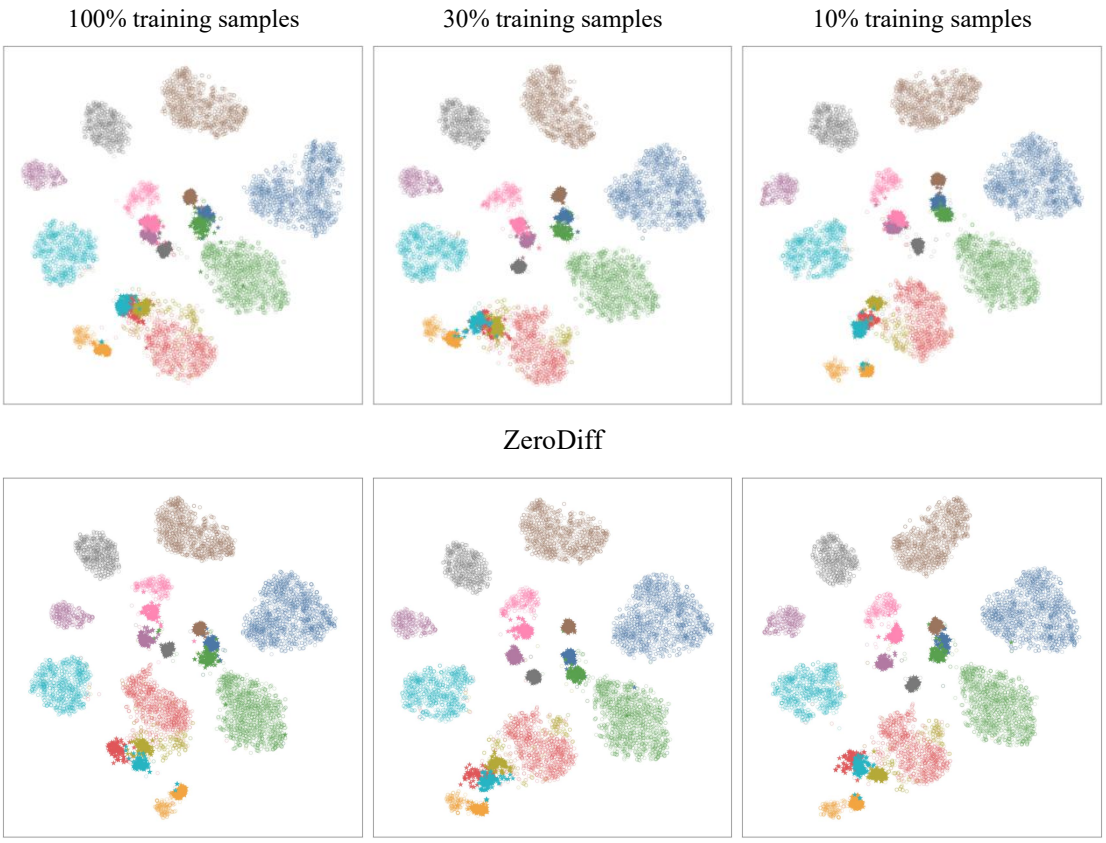


图 2 不同训练样本比例下 AWA2 未见类特征的 t-SNE 可视化。上、下排分别为 ZeroDiff 和本文方法，各列依次对应 100%、30% 和 10% 的已见类训练样本。每类展示 100 个生成样本及全部真实样本；颜色表示类别，空心圆和星形分别表示真实与生成特征。各子图采用相同设置独立降维。

两种方法均形成了若干较集中的生成特征簇，但部分不同类别的生成簇彼此邻近，且多个类别的生成特征与对应真实特征仍存在分离。在 100% 与 30% 训练样本的结果中，本文方法的部分相邻生成簇呈现较清楚的边界，例如图中部灰色生成簇与邻近粉色、紫色生成簇的分离更容易辨认。采用 10% 训练样本时，本文方法仍能形成若干可辨认的生成簇，但蓝色与绿色等相邻生成簇仍存在混叠。这些观察显示，部分局部簇结构有所改善，生成特征与真实特征之间的分布差异以及局部类别混叠仍然存在。

各子图采用相同设置独立降维，跨图的绝对位置和簇间距离不能直接比较。图 2 为表 2 的识别结果提供定性补充，其结论限于所展示样本的二维分布，不能直接推及高维关系误差或逐扩散状态的关系保持程度。

4.6.Hyperparameter Analysis

5. Conclusion